

Bio-pipeline

1. 生信

1. 对话 Gemini 总结

我现在要去面试生物分析工程师岗位，需要我有这些工作经验，你帮我提升一下能力，从基本技术，组学流程，解决问题等方面，以及我没考虑到的方面帮我提升能力。首先是单细胞组学

2. 为什么要做这些？有什么用？（比如单细胞分析：为什么要聚类 and 降维）

1.1 单细胞组学(Single-cell Omics)

原因：传统组学是把所有细胞基因混合到一起，从基因 蛋白等方面去了解生命体的基本情况。但我们已知，某些稀有细胞，或者功能细胞在体内的状态和作用不知道。需要从单个细胞的状态下去思考功能。（造血干细胞，对于白血病或者坏血病的价值。如果我们能知道他的变化情况。就能治病）

1.1.1 数据格式

1. fastq: barcode (细胞) UMI (mRNA) seq -- h5ad文件 (matrix.mtx: 基因-细胞-表达量) features.tsv (基因名) barcodes.tsv (有效细胞条形码)

2. 使用软件: CellRanger

3. 核心指标

nFeature_RNA (基因数)

nCount_RNA (UMI数)

线粒体基因比例 (MT%): 濒死细胞才有大量线粒体

1.1.2 分析流程

核心: PCA 提供了核心特征（用于计算细胞之间的关系和分群），归一化数据提供了准确的基因表达丰度（用于算差异、算通讯、建网络）

1. 预处理与降维

流程: 归一化 (Normalize) -> 寻找高变基因 (HVG) -> 数据缩放 (Scale) -> PCA 线性降维 (Principal Component Analysis) -> UMAP/tSNE 非线性降维

为什么:

归一化：测序深度差异。UMI数量不统一。LogNormalize 方法会将每个细胞的总表达量对齐

寻找高变基因 (HVG)：比如人，有些基因是无效的，表达也没用，提取高变量，去冗余

数据缩放 (Scale)：解决高变基因中，仍然特别高的。Z-score 标准化。让每个基因的平均表达量变为 0，方差变为 1

PCA 线性降维 (Principal Component Analysis)：基因在细胞的分类仍然多，且高度表达（共线性分析）。2000 个基因压缩成 30~50 个互相独立的主成分（Principal Components, PCs）

UMAP/tSNE 非线性降维：强行将高纬度PC数据变成2，3维度，便于观看结果（UMAP全局真实，tSNE局部相关）

2. 细胞注释 (Cell Annotation)

自动化注释：SingleR

手动：提取 Cluster 的差异表达基因 (Marker genes)，去 CellMarker 数据库或查阅文献比对

有什么用：比如知道什么细胞免疫细胞亚群发生了异常扩增或缺失，在白血病对照健康组

3. 细胞通讯 (Cell Communication)

基于配体-受体 (Ligand-Receptor) 在不同细胞亚群中的表达量，推断交流强度

怎么用：细胞通讯（如 CellChat）不看降维坐标，而是回到**归一化后的表达矩阵**。它提取已经注释好的不同细胞亚群，计算亚群之间“配体”和“受体”的表达丰度，从而推断出细胞群 A 和细胞群 B 之间在聊什么

有什么用：分析出受感染的靶细胞或肿瘤细胞，正是通过分泌特定的趋化因子（配体）结合到了 T 细胞的受体上，从而抑制了免疫功能。阻断这对“配体-受体”，就是制药公司开发新药的直接靶点

4. 拟时序分析 (Pseudotime/Trajectory Analysis)

假设细胞在分化/发育/疾病进展中，基因表达是连续变化的。通过算法将细胞排列在一条“时间线”上（**Monocle 2/3**（基于差异基因构建轨迹），**scVelo**（RNA速率分析，能推断未来的分化方向，面试说出这个很加分））

怎么用：拟时序算法（如 Monocle 或 scVelo）通常依赖你筛选出的**高变基因 (HVG)** 或 **PCA 降维空间** 来计算细胞之间的距离和连续状态，从而画出细胞从“早期状态”到“晚期状态”的发育演进轨迹。

有什么用：

1.2 转录组学 (Transcriptomics)


1.2.1 原理

1. 传统转录组（Bulk RNA-seq）测的是整个组织块中所有细胞的“平均表达量”，比如有些自闭症病人的多基因变异，通过对比正常人的差异性

2. 定义：细胞内所有转录产物的集合，包括**mRNA**，**rRNA**，**tRNA**以及其他non coding RNA，狭义上指mRNA 集合

1.2.2 分析流程

<https://zhuanlan.zhihu.com/p/1900307155543921775> 【完整分析流程】



1. WGCNA (加权基因共表达网络分析)

原理：已知转录组学是寻找差异基因表达来寻找患病情况，这个不同。表达模式极其相似的基因打包成几十个“模块 (Module)”，将这些基因模块直接与患者的临床特征（如宿主感染后的不同症状指标、肿瘤分期）求相关性。找出功能基因的差异性。

做法：数据清洗→软阈值确定→邻接矩阵 + TOM 矩阵→基因聚类分模块→模块 ME 与表型关联→筛选关键模块→挖掘 Hub 基因→功能富集验证

2. GSEA / GSVA (基因集富集分析 / 变异分析)

原理：GO/KEGG 只看差异基因，而 GSEA 看全局。它将所有基因按表达差异排序，看某个特定通路（如炎症反应通路）的基因是集中在序列顶部（激活）还是底部（抑制）。GSVA 则是给“每个单独的样本”计算一个通路打分

做法：

GSEA 组间分析；设置正常和非正常样本，导入基因集后，扩大富集分数

GSVA 样本组内通路打分；设置正常，导入基因集后，利用核密度排序算法，为**单个样本 - 单个通路**计算 GSVA 评分。但样本通路强弱程

3. 免疫浸润分析

原理：研究免疫细胞在组织和肿瘤环境中的分布和功能的方法

4. 预后模型构建 (Prognostic Model)

原理：基因表达量与患者的临床生存数据（OS/PFS）结合

做法：逐个基因单独跑 Cox 分析，看基因与病人生存状态是否相关，LASSO 回归【降维 + 防过拟合，删除不必要的基因】，构建风险评分公式

KM 生存曲线：高危组生存期显著更差；**ROC 曲线**：看模型预测准不准

1.3 蛋白质组学 / 网络生物学 (Proteomics / Network Biology)

1.3.1 原理

在真实的生物体内，真正去执行功能、导致疾病的“干活主力”是蛋白质。从海量数据中，揪出真正能作为药物靶点的核心分子。

1.3.2 流程

1. PPI 网络构建 (Protein-Protein Interaction)

为什么做：将转录组/蛋白质组得到的差异分子，输入到公共数据库（最经典的是 **STRING 数据库**），评估它们在蛋白质层面是否存在物理结合、共表达或进化上的共现性。然后将结果导入 **Cytoscape** 软件生成网络拓扑图

原理：蛋白质互作网络，相互关系

有什么用：枢纽分子（Hub Genes），得到价值最高的蛋白，用作后续药物研发【Degree（连通度，交际花蛋白，连的线最多）和 Betweenness（介数中心性，交通要道蛋白，扼守不同模块的咽喉）】

2. 病毒挖掘相关的应用：在挖掘 Cress 病毒等微生物样本时，不仅要看宿主内部的网络崩溃，更要利用相关工具（如 P-HIPSTer，或基于深度学习的序列特征预测）去预测**病毒蛋白是如何与宿主蛋白发生直接互作的**。病毒往往会精准“劫持”宿主 PPI 网络中的 Hub 节点。这展现了你从微观分子序列到宏观系统生物学的穿透力，非常契合底层模型挖掘的逻辑。

1.4 多组学

1.5 临床建模与方法学 (Clinical Modeling & Methodology)

1.6 机器学习

1.6.1 使用目标

1. 在什么场景下使用什么样的算法

1.6.2 举例

特点：生信数据（尤其是转录组或多组学）最大的特点是“**样本少，特征多**”——比如只有 100 个病人，却有 2 万个基因。传统统计学（如 T 检验）只能告诉你某个基因在两组间“有显著差异”，但**机器学习能告诉你“这几个基因组合在一起，能精准预测未来的疾病走向”**

1. LASSO 回归 (Least Absolute Shrinkage and Selection Operator)

作用：那些个基因能决定病毒高发率？防止过拟合，如何选择系数？交叉验证(Cross-Validation)

原理：线性回归，加入惩罚力度（ λ ）的增加，它会强行把那些对预测贡献不大或存在多重共线性的基因系数压缩成**绝对的 0**。

2. 随机森林 (Random Forest, RF)

作用：基因的**重要性**

原理：构建成百上千棵决策树，每棵树随机抽取部分样本和部分基因进行训练，最后让所有树“投票”决定分类。通过计算剥夺某个基因后模型准确率下降的程度（Mean Decrease Gini / Mean Decrease Accuracy），来评估这个基因的**重要性**

3. SVM-RFE (支持向量机-递归特征消除)

作用：引发疾病准确率最高的那一小撮“黄金基因”组合

原理：用 SVM 训练模型，给所有基因的权重打分，然后**剔除排名垫底的那个（或那一批）基因**。接着用剩下的基因重新训练，重复这个过程

4. 整体思维：

筛选基因：通常会提取 LASSO 选出的特征、随机森林计算出的高重要性特征，以及 SVM-RFE 筛选的特征，**取这三者的交集**。这样筛选出的核心靶点，兼顾了线性与非线性、稳健性与极简性，后续在临床队列里的验证成功率最高

1.7 面试总结

1. 提问的问题：

公共数据库的挖掘

如果面试官问你，XX有了解过吗？就是问你相关的流程是怎么做的